

Neuronske mreže proučavaju se u računarstvu u okviru područja neuro-računarstva koje je dio grane mekkog računarstva. Mozak se sastoji od  $10^{11}$  neurona, svaki povezan u prosjeku s 4500 neurona. Obrada informacija u mozgu dominantno se odvija paralelno. Dva su pristupa u razvoju inteligentnih sustava: simbolički i konektivistički. Neuronske mreže dobro rješavaju probleme klasifikacije i predviđanja. Dvije su faze u radu s neuronskom mrežom: faza učenja i faza obrade podataka. Tijekom učenja, jedno predočavanje svih uzoraka naziva se epohom. Razlikujemo dva načina učenja: pokidinačno kod kojeg se promjena događa nakon svakog predočenog uzorka te grupno kod kojeg se promjena događa tek nakon što se mreži predoče svi uzorci. Znanje neuronske mreže pohranjeno je u težinama veza neurona. Dva su načina učenja: ako mreži dajemo parove (ulaz, izlaz) govorimo o podznanom učenju a ako mreži dajemo samo ulaz, govorimo o nerazdvojenom učenju. Skup primjera za učenje dijelimo na skup za (1) učenje, skup za (2) testiranje te na skup za (3) pragiranje. Kada pogreška na skupu (2) počinje rasti a na skupu (1) i dalje pada, kažemo da je došlo do pretrčavanja neuronske mreže. Prvi model umjetnog neurona iz 1943. autora McCullocha i Pittsa je Threshold Logic Unit. Jakost sinapse kod njega je opisana težinskom funkcijom, tijelo stanice je modelirano sumom težinskih fga dok je akson modeliran sigmoidskom funkcijom. Izlaz umjetnog neurona opisan je izrazom  $o = f(\text{net}) = f(\sum_{i=1}^n w_i x_i)$ . Kada govorimo o ADALINE-umjetnom neuronu,  $f(\text{net}) = \text{net}$ . Kod TLU-umjetnog neurona  $f(\text{net}) = \text{N}(\text{net})$ .

Svaki uzorak opisujemo nizom brojeva. Klasifikaciju uobičajeno činimo na temelju svih?/nekih? značajki. Značajke korištene za definiranje koncepta "Dobra tajnica" su komunikativnost i snalažljivost. Razred "Dobra tajnica" predstaviti ćemo brojem 1 a suprotan razred ne "Dobra tajnica" brojem -1. Kod TLU-perceptrona granica je hiperravna. Kažemo da je klasifikaciju moguće obaviti TLU-perceptronom samo ako su razredi linearno razdvojeni. Prema Hebbu, učiti znači mijenjati jakosti veza. Tu ideju Hebba i TLU-model umjetnog neurona spojio je američki znanstvenik Rosenblatt u pravilo perceptrona. Izraz za korekciju težina u tom pravilu glasi  $w_i(k+1) = w_i(k) + \eta (t - o) x(k)$ . Primjer problema koji jedan TLU-perceptron ne može riješiti je XOR funkcija. To su, između ostaloga u svojoj knjizi "Perceptrons: An Introduction to Computational Geometry" istaknuli autori Minsky i Papert. Višeslojne neuronske mreže u to se vrijeme nisu mogle učiti jer se nije znalo kako riješiti problem djeljivosti zadatke (credit assignment).



Unaprijedne neuronske mreže gradimo uporabom neurona s linearnim?/nelinearnim? prijenosnim funkcijama.

Sigmoidalna prijenosna funkcija definirana je izrazom  $f(x) = \frac{1}{1+e^{-net}}$  a njezina je derivacija

$df(x)/dx = f(x)(1-f(x))$ . Ta je funkcija derivabilna pa u svakoj točki ima

definiran gradijent. Pravilo učenja koje je riješilo problem lokalne zadatke

zove se backpropagation. Ukupna pogreška nad svim uzorcima kod

višeizlazne unaprijedne neuronske mreže definirana je izrazom:  $E(\vec{w}) = \frac{1}{2} \sum_{d \in D} \sum_{k \in \text{outputs}} (t_{kd} - o_{kd})^2$ .

Pogreška izlaznog neurona  $\delta_j = o_j(1-o_j)(t_j - o_j)$ . Pogreška neurona koji nije u izlaznom

sloju pogrešku računa temeljem izračunatih pogrešaka neurona kojima je on ulazni neuron, i to prema izrazu

$\delta_i = o_i(1-o_i) \cdot \sum_{j \in \text{SESS}} w_{ij} \delta_j$ . Težina  $w_{ij}$  tada se korigira za iznos  $\Delta w_{ij} = \eta \delta_j o_i$ .

Za slobodne težinske faktore  $o_i = 1$ . Kod pojedinačnog učenja, ugađanje težina se radi


pojedinačno; takva izvedba algoritma poznata je

pod nazivom stohastički backpropagation. Kod grupnog učenja, korekcija težina

se vrši tek nakon što su mreži predloženi svi primjeri za učenje

i primjenjuje s faktorom  $\eta$  tek nakon što su mreži predloženi svi uzorci.

$\eta = 0.02$ ,  $\{(x_2, x_1) = o\} = \{(2, 5) = 1, (5, 2) = 1, (1, 5) = -1, (5, 1) = -1\}$ ,  $w_i(k+1) = w_i(k) + \eta(t - o)x(k)$

Br.	$w_2$	$w_1$	$w_0$	$x_2$	$x_1$	$x_0$	$t_{out}$	net		Kor?	$\eta(t-p)$	Račun
1	1	1.3	-5.85	2	5	1	1	2.65	1	NE	0	1
2	1	1.3	-5.85	5	2	1	1	1.75	1	NE		
3	0.1	1.3	-5.85	1	5	1	-1	1.65	1	DA	-0.04	
4	0.96	1.1	-5.89	5	1	1	-1	0.01	1	DA	-0.04	
1	0.76	1.06	-5.93	2	5	1	1	0.81	1	NE		
2	0.76	1.06	-5.93	5	2	1	1	-0.01	-1	DA	0.04	
3	0.96	1.14	-5.89	1	5	1	-1	0.77	1	DA	-0.04	
4	0.92	0.94	-5.53	5	1	1	-1	-0.39	-1	NE		
1	0.92	0.94	-5.53	2	5	1	1	0.61	1	NE		
2	0.92	0.94	-5.53	5	2	1	1	0.55	1	NE		
3	0.92	0.94	-5.53	1	5	1	-1	-0.31	-1	NE		
4			-5.53	5	1	1	-1					